



Московский государственный университет имени М.В. Ломоносова

Факультет вычислительной математики и кибернетики

Кафедра математической физики

Индычко Олеся Игоревна

**Адаптация изображений аншлифов, полученных в
разных условиях съемки, в задаче сегментации
минералов**

КУРСОВАЯ РАБОТА

Научный руководитель:

к.ф-м.н., м.н.с.

А.В. Хвостиков

Москва, 2022

Оглавление

1 Введение	3
1.1 Описание предметной области	3
1.2 Анализ существующих подходов	3
1.3 Предлагаемый подход	4
2 Цель работы	5
3 Предлагаемый метод адаптации	6
3.1 Используемые данные	6
3.2 Алгоритм совмещения изображений	7
3.3 Алгоритм цветовой калибровки	8
3.4 Полный алгоритм адаптации	11
4 Результаты	14
5 Заключение	17
6 Дальнейшее развитие	18

1. Введение

1.1. Описание предметной области

В геологии существует важная задача – анализ минерального состава руд и вмещающих пород. Используемый на данный момент способ исследования – оптический, заключающийся в изучении под микроскопом аншлифов и шлифов. Аншлиф – образец горной породы, подготовленный особым образом: его поверхность шлифуется и полируется для изучения препарата в отраженном свете под микроскопом. Отличие шлифа заключается в том, что подготовленный образец изучается в проходящем свете.

Обозначенная задача очень сложная и требует больших затрат рабочего времени высококвалифицированных специалистов-геологов. Именно поэтому особенно актуальны решения с применением нейронных сетей, обеспечивающие автоматическую сегментацию минералов. Построенные модели позволяют значительно ускорить процесс анализа аншлифов, но все еще не гарантируют идеальную точность.

Одной из трудностей в работе моделей автоматической сегментации минералов с использованием методов машинного обучения является неоднородность обучающих и тестовых данных. На изображения аншлифов сильно влияют условия съемки: оборудование, освещение, расположение образца, настройка камеры и др. Нередко снимки получаются очень разными – см. Рис. 1.

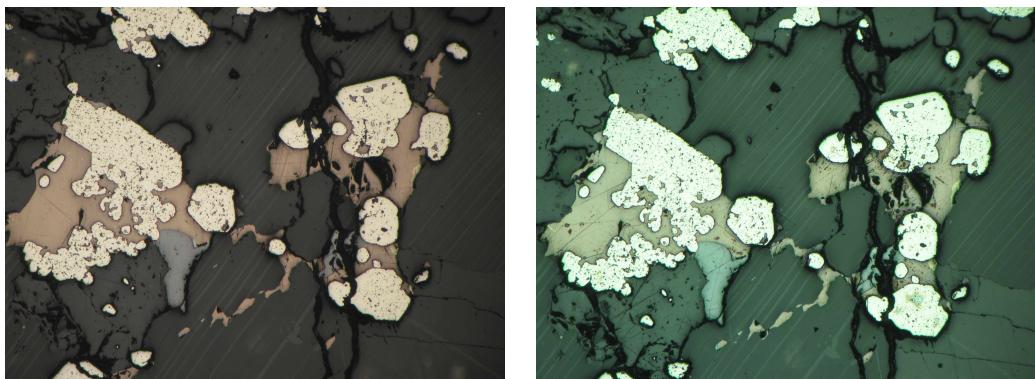


Рис. 1: Изображения одного аншлифа, полученные в разных условиях съемки.

Поэтому крайне важно обеспечить одинаковое качество работы модели сегментации на данных, собранных в разных условиях.

1.2. Анализ существующих подходов

Классический способ добиться относительно хорошего качества на разнородных данных – **аугментация обучающей выборки**. Поворот и смещение изображения – простые

трансформации, активно используемые в аугментации. Но искусственно создать цветовые искажения, имитирующие изменения условий съемки, с помощью элементарных преобразований крайне сложно.

Существует другой подход, активно набирающий популярность в последнее время – **доменная адаптация**. Этот подход заключается в обучении глубокой нейронной сети на данных из домена-источника таким образом, чтобы модель показывала сравнимое качество сегментации на целевом домене. Метод используется во многих областях, в том числе и в геологии, например, в задаче анализа сейсмических фаций, т. е. пластов осадочных пород, обладающих определенными свойствами [1]. К минусам данного подхода можно отнести сложность реализации и плохую интерпретируемость.

1.3. Предлагаемый подход

Существующие подходы так или иначе приводят к изменению модели сегментации, чего хотелось бы избежать. Поэтому был выбран подход «с другой стороны»: **адаптировать входные изображения** под обученную нейронную сеть, а не модифицировать модель.

В работе представлен метод, улучшающий точность сегментации с помощью предобработки входного изображения аншлифа. Входными данными для алгоритма являются референсное изображение части аншлифа из выборки, на которой обучалась модель сегментации, полная маска сегментации этого изображения и новый снимок того же фрагмента, сделанный в других условиях съемки. Результатом работы является преобразованный новый снимок, имеющий цвето-яркостные характеристики, максимально приближенные к референсным. Предлагаемый подход использует математические методы обработки изображений, что обеспечивает хорошую интерпретируемость.

Выбранный подход позволяет производить оценку качества адаптации с помощью сравнения точности работы обученной модели сегментации на изображениях, полученных в разных условиях съемки, с реализованной адаптацией и без нее.

2. Цель работы

Целью работы является разработка алгоритма, осуществляющего адаптацию изображений аншлифов, полученных в разных условиях съемки, с использованием размеченного набора референсных изображений.

План работы включает в себя следующие этапы:

1. Получение набора данных, для каждого элемента которого имеется: референсное изображение аншлифа, маска сегментации данного изображения, вариации снимка того же аншлифа в разных условиях съемки;
2. Разработка алгоритма совмещения референсного изображения с его вариациями;
3. Разработка алгоритма цветовой калибровки для приведения цвето-яркостных характеристик изображений, сделанных в отличающихся условиях съемки, к референсным значениям;
4. Оценка работы реализованного алгоритма при помощи существующей модели сегментации минералов.

3. Предлагаемый метод адаптации

3.1. Используемые данные

В работе использован поднабор S1 набора данных LumenStone¹, содержащий снимки анишлифов в разрешении 3396×2547 пикселей и полные семантические маски сегментации для каждого изображения (см. Рис. 2).

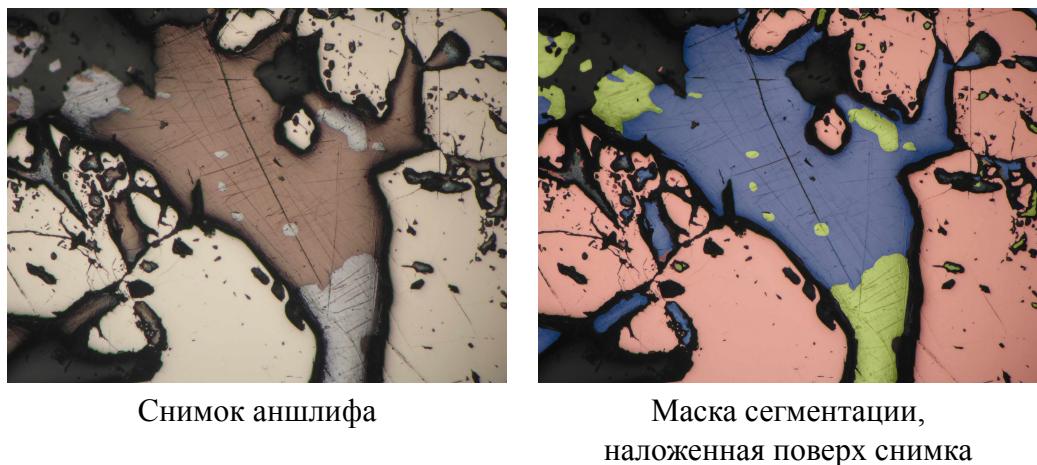


Рис. 2: Пример данных из датасета LumenStone.

Для решения задачи адаптации данные были пополнены изображениями тех же анишлифов, сделанных в других условиях съемки (см. Рис. 3).

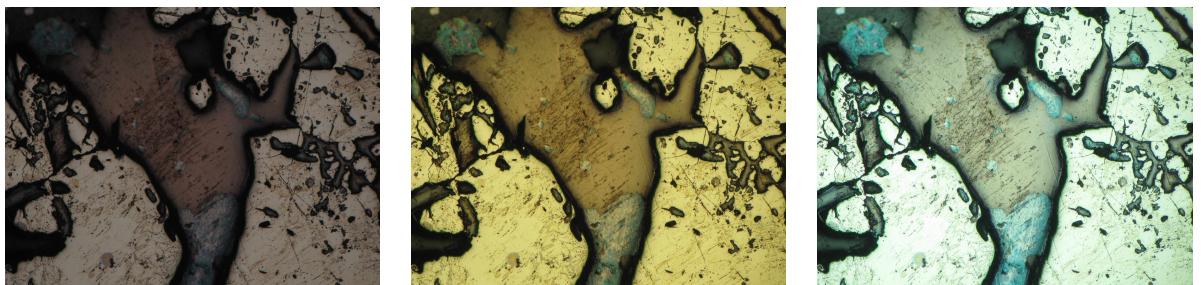


Рис. 3: Изображения одного и того же анишлифа, сделанные в разных условиях съемки.

Набор данных LumenStone насчитывает 104 изображения. Для восьми из которых было сделано 5-7 новых изображений с вариациями условий съемки, далее эти изображения будем считать искаженными. На оригинальных 104 снимках была обучена модель автоматической сегментации. Далее в работе под референсными изображениями будет подразумеваться именно эта обучающая выборка.

¹<https://imaging.cs.msu.ru/en/research/geology/lumenstone>

3.2. Алгоритм совмещения изображений

Процесс совмещения изображений можно разбить на три этапа:

1. Выделение на изображениях ключевых точек и их дескрипторов;
2. Сопоставление ключевых точек на двух изображениях;
3. Построение модели преобразования, с помощью которой одно изображение переходит в другое.

Для поиска ключевых точек и их дескрипторов используется масштабно-инвариантная трансформация признаков (SIFT) [2]. Главной идеей работы алгоритма является анализ сверток входных изображений с разными ядрами гаусса – гауссианами изображений. Первым этапом строится пирамида гауссианов и их разностей (см. Рис. 4). Особыми точками объявляются точки локального экстремума разности гауссианов. Далее с помощью матрицы Гессе из особых точек выбираются ключевые. Для каждой ключевой точки вычисляется ее направление, исходя из направлений градиентов соседних с ней точек.

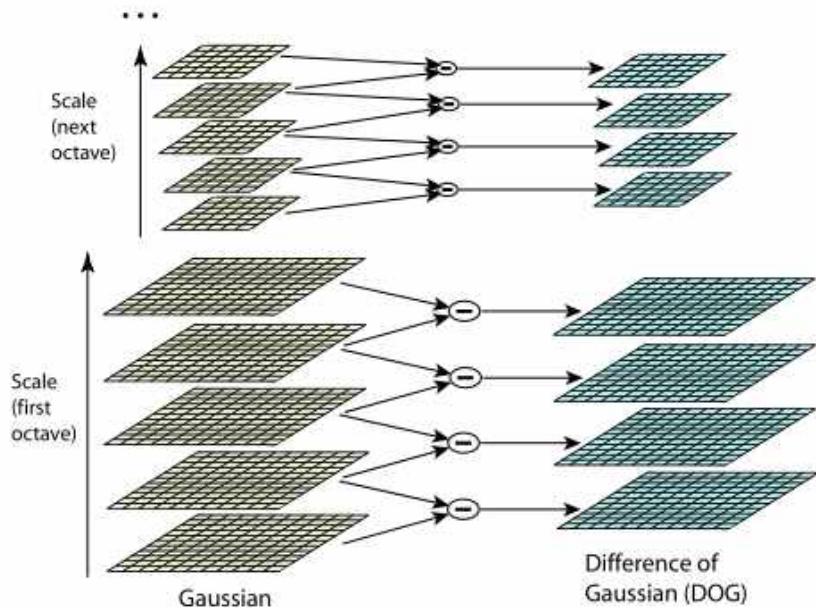


Рис. 4: Схематичное построение пирамиды гауссианов и их разностей.

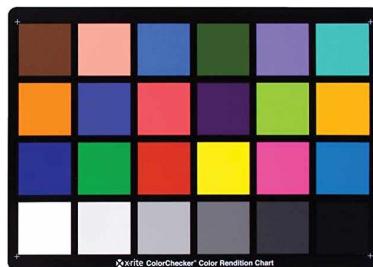
Вторым этапом работы алгоритма является построение дескрипторов ключевых точек, т. е. разного рода идентификаторов, выделяющих каждую ключевую точку из всей массы особенностей. В SIFT дескриптором является вектор из 128 компонент. Для вычисления дескриптора ключевой точки выбирается гауссиан, полученный сверткой изображения с гауссовым ядром радиуса $\sigma = 1.5m$, где m – масштаб ключевой точки. Дескриптор находится как некоторая функция градиентов в выбранном окне ключевой точки.

Для сопоставления ключевых точек на изображениях использована модель на основе Fast Library for Approximate Nearest Neighbors [3] (FlannBasedMatcher). Алгоритм строит k-d-дерево (оно же k-мерное дерево) для быстрого поиска ближайшего соседа. В данном случае для поиска максимально совпадающих дескрипторов двух ключевых точек.

Последним этапом строится матрица гомографии размера 3×3 , отображающая ключевые точки одного изображения в ключевые точки второго. Для вычисления матрицы гомографии необходимо знать минимум 4 точки, которые должен извлечь SIFT. Реализация поиска матрицы преобразования в библиотеке OpenCV [4] оценивает гомографию таким образом, чтобы обеспечить наилучшее соответствие для всех найденных ключевых точек.

3.3. Алгоритм цветовой калибровки

За основу реализованного в данной работе алгоритма цветовой калибровки был взят алгоритм Color Correction Model² (CCM), используемый для коррекции цвето-яркостных характеристик изображения с помощью различных шкал цветопередачи (физических карточек с цветовой палитрой). Целью этой модели является максимальное приближения цветов палитры на входном изображении к референсным, полученным от создателей шкалы. Пример работы CCM представлен на Рис. 5.



Используемая шкала цветопередачи



Входное изображение



Результат работы CCM

Рис. 5: Пример работы Color Correction Model.

²https://github.com/riskiest/color_calibration/



Рис. 6: Процесс обучения Color Correction Model.

Процесс обучения модели цветовой коррекции можно представить в виде блок-схемы, изображенной на Рис. 6. Далее этот процесс рассмотрен более подробно.

1. Входное цветовое пространство – извлеченные (каким-либо образом) данные о цветах калибровочной шкалы на входном изображении, собранные в виде

$$CS^{inp} = \begin{bmatrix} [R_1, G_1, B_1] \\ [R_2, G_2, B_2] \\ \dots \\ [R_N, G_N, B_N] \end{bmatrix},$$

где N – количество цветов шкалы, $[R_i, G_i, B_i]$ – красная, зеленая и синяя компоненты i -го цвета шкалы соответственно.

2. Извлеченные цвета могут нелинейно зависеть от яркости, из-за чего невозможно построить линейное преобразование, эффективно приближающее входное цветовое пространство к референсному. Процесс линеаризации исправляет эту проблему. Существуют несколько методов линеаризации, используемых на практике: гамма-коррекция, полиномиальное преобразование, логарифмическая трансформация и др.

Подробно остановимся на гамма-коррекции [5], используемой в модели. Пусть C_i^{inp} – любой из трех каналов i -го цвета из CS^{inp} , C_i^{lin} – значение C_i^{inp} после линеариза-

зации. Тогда формулы гамма-коррекции выглядят следующим образом

$$C_i^{lin} = \begin{cases} (C_i^{inp})^\gamma, & C_i^{inp} \geq 0, \\ -(-C_i^{inp})^\gamma, & C_i^{inp} < 0, \end{cases}$$

где γ – параметр гамма-коррекции, обычно выбирается значение $\gamma = 2.2$.

Применив гамма-коррекцию, получаем линеаризованное цветовое пространство

$$CS^{lin} = \begin{bmatrix} [R_1^{lin}, G_1^{lin}, B_1^{lin}] \\ [R_2^{lin}, G_2^{lin}, B_2^{lin}] \\ \dots \\ [R_N^{lin}, G_N^{lin}, B_N^{lin}] \end{bmatrix}.$$

Подразумевается, что референсное цветовое пространство $RCS = RCS^{lin}$ является линеаризованным.

- На этом этапе осуществляется цветовая коррекция. M_{CCM} (Color Correction Matrix) – матрица размера 3×3 , осуществляющая некоторое линейное преобразование значений $[R_i^{lin}, G_i^{lin}, B_i^{lin}]$. Преобразованное цветовое пространство CS^{adj} имеет вид:

$$CS^{adj} = CS^{lin} \times M_{CCM} = CS^{lin} \times \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}.$$

О вычислении значений матрицы M_{CCM} будет рассказано позже, во время описания процесса минимизации функции потерь.

- На этапе преобразование цветового пространства из RGB в LAB необходимо, чтобы пространство RGB было линеаризовано, именно для этого ранее выполнялась гамма-коррекция. Переход в цветовое пространство LAB позволяет использовать формулу цветового отличия (color difference) CIEDE2000 [6]. На ее основе будет построена функция потерь $Loss$.

Также необходимо преобразовать в LAB и референсное цветовое пространство RCS^{lin} .

- На данном этапе есть два, преобразованных в LAB, цветовых пространства: референсное CS^{ref} и преобразованное входное CS^{adj} . Функция потерь $Loss$ выбирается как сумма квадратов цветовых отличий, вычисленных по формуле CIEDE2000.

Необходимо подобрать матрицу M_{CCM} таким образом, чтобы значение функции потерь $Loss$ было минимальным. Задача минимизации решается методом наименьших квадратов. Определим начальные значения матрицы M_{CCM} . Возьмем матрицы цветовых пространств входного $CS^{lin} = S_{lin}$ и референсного $RCS^{lin} = D_{lin}$ после их линеаризации. Инициализируем матрицу M_{CCM} следующим образом

$$M_{CCM} = (S_{lin}^T S_{lin})^{-1} S_{lin}^T D_{lin}.$$

Итеративная минимизация функции потерь до заданного порога точности дает решение задачи цветовой калибровки – матрицу M_{CCM} .

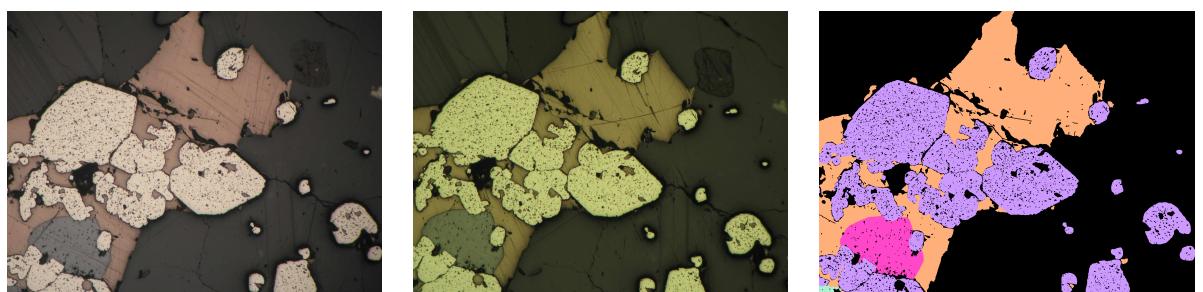
После того как модель цветовой коррекции обучена, можно приступать к преобразованию изображений по схеме, представленной на Рис. 7.



Рис. 7: Процесс преобразования изображения обученной моделью.

3.4. Полный алгоритм адаптации

В данном подразделе будет описан полный алгоритм адаптации геологического изображения. На вход подаются три изображения: референсное, искаженное и маска сегментации референсного (см. Рис. 8).



Референсное изображение

Искаженное изображение

Маска сегментации

Рис. 8: Пример входных данных для алгоритма адаптации.

Шаг 1. Совмещение изображений. В связи с большим количеством ключевых точек разного масштаба на изображении аншлифа существует большая погрешность при совмещении полноразмерных снимков. Чтобы повысить точность совмещения, будем совмещать не все референсное изображение с искаженным, а фрагмент референсного изображения, содержащий как можно больше деталей.

Используя маску сегментации, найдем область размером 800×800 пикселей, содержащую максимальное число разных минералов, и вырежем ее. С помощью алгоритма совмещения, описанного в разделе 3.2, совместим полученный фрагмент с искаженным изображением. Результат совмещения представлен на Рис. 9.

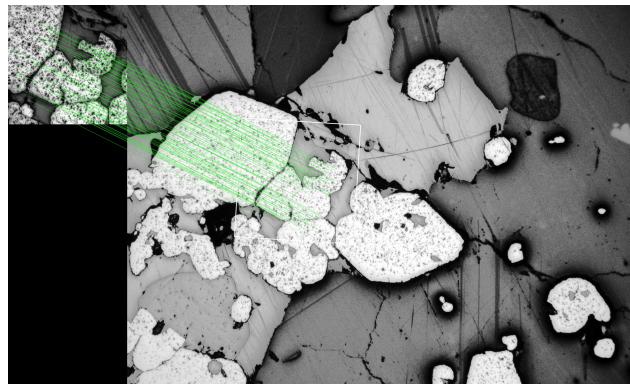
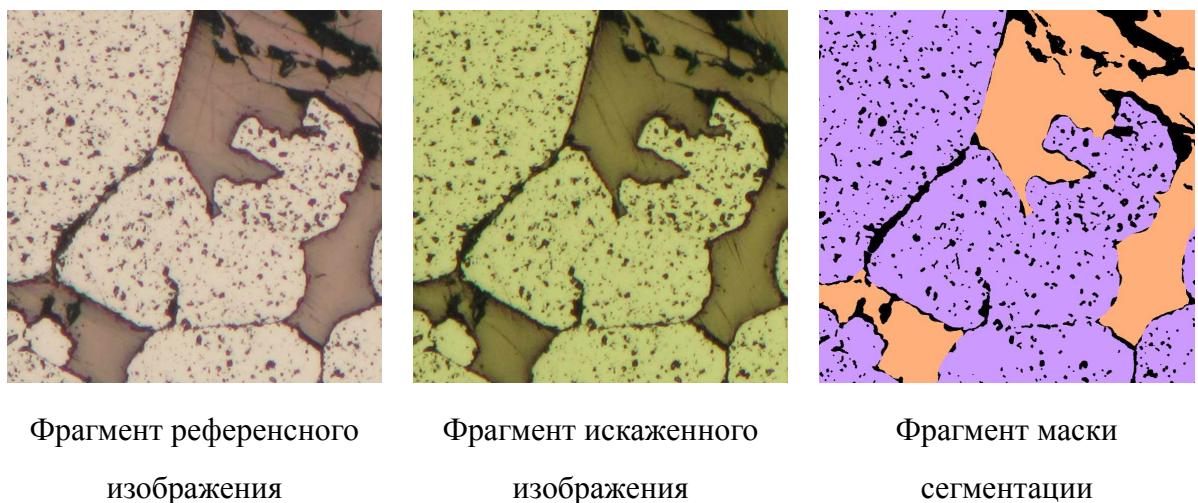


Рис. 9: Результат работы алгоритма совмещения.

Шаг 2. Извлечение цветовых пространств. После некоторой постобработки (применение трансформации, обрезка и др.) получим фрагменты референсного изображения, его маски и искаженного изображения, полностью совмещенные между собой (см. Рис. 10). Именно эти фрагменты будут использованы для получения информации о цветовых распределениях.



Фрагмент референсного изображения Фрагмент искаженного изображения Фрагмент маски сегментации

Рис. 10: Совмещенные на первом шаге фрагменты.

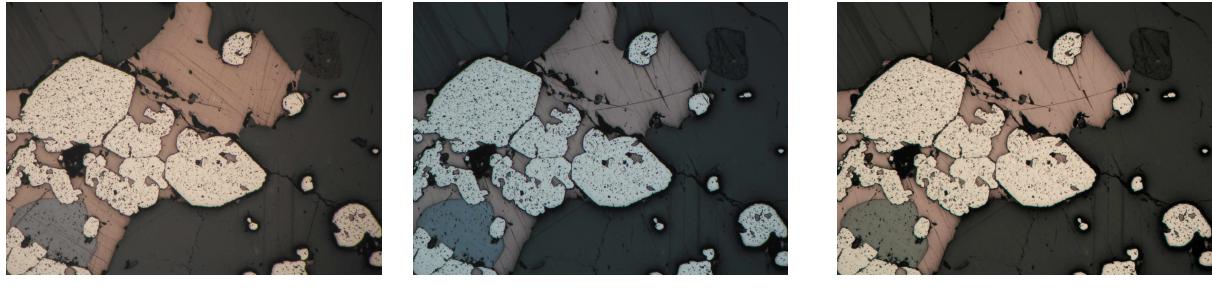
По маске сегментации вычисляется число уникальных минералов на изображениях, а после

считается среднее значение красной, синей и зеленой компонент для каждого минерала на референсном и искаженном изображениях. Таким образом составлены две матрицы цветов, которые будут использованы для цветовой калибровки.

Шаг 3. Цветовая калибровка. На извлеченном референсном цветовом пространстве обучается модель CCM , а после искаженное изображение целиком преобразуется. С примерами работы алгоритма и результатами можно ознакомиться далее.

4. Результаты

Реализованным алгоритмом адаптации визуально удалось достичь значительного приближения цветового распределения на изображениях к референсному (см. Рис. 11).



Референсное изображение Исаженное изображение Адаптированное изображение

Рис. 11: Пример результата работы реализованного алгоритма адаптации.

Для оценки качества работы алгоритма адаптации в данной работе оценивается точность автоматической сегментации на наборе референсных изображений и адаптированных. Чем ближе полученные значения, тем лучше работает реализованный метод. Пример работы модели автоматической сегментации представлен на Рис. 12

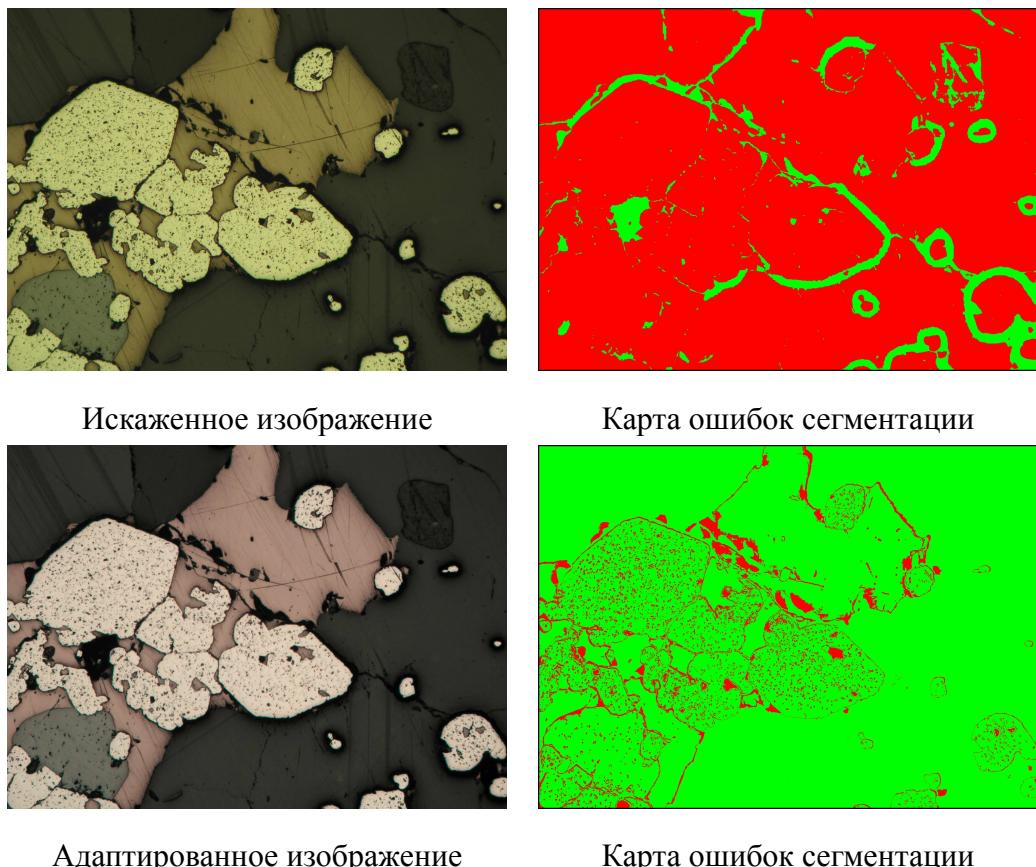


Рис. 12: Пример автоматической сегментации искаженного и адаптированного изображений.

Набор изображений, на котором происходила оценка состоял из восьми референсных изображений и 24 искаженных. Для составления набора искаженных изображений были выбраны три варианта условий съемки (см. Рис. 13), в которых были сделаны снимки всех референсных изображений.

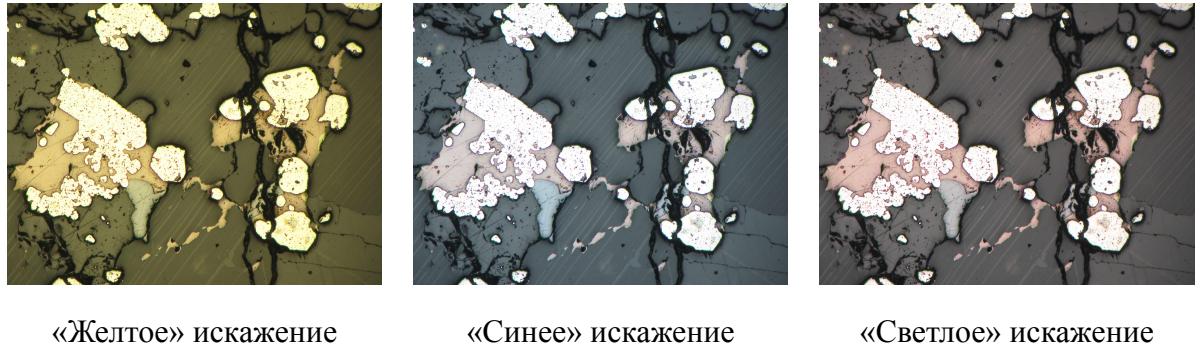


Рис. 13: Выбранные искажения для оценки качества работы алгоритма адаптации.

Искаженные изображения предварительно были совмещены с референсными, что позволило использовать одни и те же маски сегментации. В таблице, представленной на Рис. 14, приведены результаты качества сегментации подготовленного набора изображений. В первой строке отображены значения метрик на наборе из восьми референсных изображений. Далее результаты сегментации 24 искаженных изображений и их адаптированных вариантов. В строках ниже представлены результаты сегментации наборов из 8 изображений для каждого из трех искажений.

Тип	Точность	Intersection over Union (IOU)						
		BG	Ccp	Gl	Brт	Py/Mrc	Sph	Tnt/Ttr
Референсное	0.9504	0.9351	0.8585	0.8560	0.9140	0.9270	0.6988	0.5565
Искаженное	0.2482	0.3770	0.0408	0.0510	0.0228	0.1886	0.0027	0.0340
Адаптированное	0.6029	0.5667	0.2262	0.1831	0.5173	0.5207	0.1019	0.1503
Желтое искаж.	0.2053	0.2294	0.0398	0.0000	0.0000	0.3768	0.0000	0.0000
Желтое адапт.	0.5262	0.6042	0.0691	0.1341	0.4472	0.2250	0.2089	0.0274
Синее искаж.	0.2911	0.5136	0.0661	0.0572	0.0456	0.0210	0.0031	0.0372
Синее адапт.	0.4858	0.4601	0.2182	0.1293	0.2436	0.6065	0.0104	0.3904
Светлое искаж.	0.4552	0.5004	0.1120	0.1094	0.1517	0.5031	0.0251	0.0008
Светлое адапт.	0.7495	0.6337	0.7334	0.4252	0.6877	0.6800	0.1950	0.0117

Рис. 14: Оценка качества автоматической сегментации минералов.

Алгоритм адаптации больше чем в два раза улучшил точность сегментации и значения метрики IOU для встречающихся минералов. По абсолютным числам лучше всего алгоритму удалось обработать «светлое» искажение, зато если смотреть относительные значения метрик, то адаптация изображений с «желтым» искажением способствовала наибольшему увеличению точности. Но изначальная цель – максимально приблизиться к значениям метрик для референсных изображений – все еще не достигнута. В заключении будут предложены способы улучшения реализованного алгоритма.

5. Заключение

Был разработан алгоритм адаптации изображений анишлифов, полученных в разных условиях съемки. Предложенный метод был программно реализован на языке Python3 с использованием библиотек scikit-image [7], OpenCV и NumPy. Программная реализация представлена в интерактивной среде Jupyter Notebook³.

Метод был протестирован на наборе данных из восьми референсных изображений и 24 искаженных и показал увеличение качества автоматической сегментации более чем в два раза по сравнению с точностью на искаженных изображениях. Тем не менее добиться значений метрик, сравнимых со значениями на референсном наборе, не удалось. Предлагается следующая доработка алгоритма адаптации:

- улучшение алгоритма совмещения для работы с большими фрагментами изображений;
- уточнение подбора матрицы цветовой коррекции с помощью увеличения числа пикселей, задействованных в извлечении цветовых пространств.

³https://github.com/luseno4ek/geology_image_adaptation

6. Дальнейшее развитие

В продолжение работы над задачей будет реализовано приложение, осуществляющее адаптацию изображений с помощью информации, полученной от пользователя. Такой подход позволит избавиться от использования полной маски сегментации – данных, для получения которых требуются большие затраты рабочего времени специалистов-геологов. На данный момент предполагаются два варианта получения информации от пользователя:

- пользователь предоставляет частичную разметку характерных минералов с помощью штрихов или точек входного изображения, сделанного в новых условиях;
- пользователь предварительно калибрует алгоритм к своим условиям съемки, представляя снимок специально подготовленного аншлифа, для которого имеется полная маска сегментации.

Список литературы

- [1] Seismic Facies Analysis: A Deep Domain Adaptation Approach / Nasim M. Q., Maiti T., Srivastava A., Singh T., and Mei J. // arXiv. — 2020.
- [2] LoweDavid G. Distinctive Image Features from Scale-Invariant Keypoints // International Journal of Computer Vision. — 2004.
- [3] Muja M., Lowe D. Fast Approximate Nearest Neighbors with Automatic Algorithm Configuration. — 2009.
- [4] A brief introduction to OpenCV / Culjak I., Abram D., Pribanic T., Džapo H., and Cifrek M. — 2012.
- [5] Poynton C. Digital Video and HD: Algorithms and Interfaces. Computer Graphics. — Elsevier Science, 2003.
- [6] Sharma G., Wu W., Dalal E. The CIEDE2000 color-difference formula: Implementation notes, supplementary test data, and mathematical observations // Color Research & Application. — 2005.
- [7] scikit-image: image processing in Python / van der Walt S., Schönberger J. L., Nunez-Iglesias J., Boulogne F., Warner J. D., Yager N., Gouillart E., Yu T., and the scikit-image contributors // PeerJ. — 2014.